

从线性代数到张量计算

Tensor Computations: An Algebraic Perspective

陈新宇

程展鸿

赵熙乐

孙立君

发布时间：2022 年 11 月

更新时间：2022 年 12 月

目录

| | |
|--------------------------------------|-----------|
| 第一章 代数结构 | 7 |
| 1.1 向量与矩阵 | 7 |
| 1.2 张量 | 7 |
| 1.2.1 张量结构 | 7 |
| 1.2.2 高阶张量矩阵化 | 7 |
| 1.3 特殊代数结构 | 7 |
| 1.3.1 循环矩阵 | 7 |
| 1.3.2 卷积矩阵 | 8 |
| 1.3.3 Hankel 矩阵 | 8 |
| 第二章 Kronecker 积与 Kronecker 分解 | 9 |
| 2.1 Kronecker 积定义 | 9 |
| 2.2 Kronecker 积基本性质 | 10 |
| 2.2.1 结合律与分配律 | 10 |
| 2.2.2 矩阵相乘 | 12 |
| 2.2.3 求逆矩阵 | 12 |
| 2.2.4 向量化 | 13 |
| 2.3 Kronecker 积特殊性质 | 13 |
| 2.4 朴素 Kronecker 分解 | 13 |
| 2.4.1 定义 | 13 |
| 2.4.2 引入 permute 概念 | 13 |
| 2.4.3 求解过程 | 14 |
| 2.5 广义 Kronecker 分解 | 15 |
| 2.6 模型参数压缩问题 | 16 |
| 第三章 模态积与 Tucker 张量分解 | 19 |
| 3.1 模态积定义 | 19 |
| 3.2 模态积性质 | 19 |
| 3.3 高阶奇异值分解 | 19 |
| 3.4 Tucker 分解 | 19 |
| 第四章 低秩线性回归 | 21 |
| 4.1 低秩线性回归 | 21 |
| 4.2 高维向量自回归 | 21 |
| 4.3 时变低秩向量自回归 | 21 |

前言

在过去的数十年间，随着信号处理、机器学习与数值计算等领域的快速发展，张量计算已从以线性代数为基础的矩阵计算中逐步拓展开来，相关研究贯穿信号处理、机器学习等众多领域。随着大量张量计算算法涌现出来，我们不难发现：这些算法大多建立在张量分解的基础上。本文以张量计算这一概念为核心，将从线性代数出发，讲述张量计算相关的一系列内容。为了提高读者的阅读体验，笔者进行了以下尝试：

- **化繁为简**。将线性代数以及张量计算的范畴限定在实空间中。另外，严格来说，向量和矩阵属于低阶张量，为区分概念，我们默认常提到的张量特指高阶张量（阶数大于或等于 3）。
- **由浅入深**。从基本的线性代数内容展开，通过循序渐进的方式引出一系列矩阵分解与张量分解技术，使读者体会到线性代数的巨大价值。
- **熟能生巧**。本文在撰写过程中尽可能考虑初学者的学习历程，在全文中设计一系列难度适中的例题让读者更直观理解一系列理论，并通过练习熟练掌握相应内容。

笔者深感自身才疏学浅，对于线性代数和张量计算的认识具有一定的局限性，请广大读者批评指正。另外，全文内容设置的合理性也有待考究，需要等待读者的检验。尽管如此，笔者愿竭心力，在后续版本中逐步更新与完善本文，如有建议或疑问，请在 GitHub 开源项目<https://github.com/xinychen/tensor-book>的问答区与笔者进行互动交流。

作者声明：

- 撰写本文的初衷在于传播知识，为感兴趣的读者提供参考素材。
- 禁止将本文放在其他网站上，唯一下载网址为https://xinychen.github.io/books/tensor_book.pdf。
- 禁止将本文用于任何形式的商业活动。

第一章 代数结构

长期以来，线性代数一直作为机器学习中最重要数学工具之一，被人们广泛用于开发各类机器学习算法。线性代数本质上是以向量与矩阵为基本代数结构，本书要讨论的张量分解等模型则主要以张量为基本代数结构。在过去的数十年间，借助线性代数这一基本数学工具，机器学习中涌现出了很多经典的代数模型，这其中不乏矩阵分解、主成分分析，而张量分解在某种程度上可看作是矩阵分解的一种衍生物。

近年来，张量分解在机器学习的众多问题中得到了很好的应用，但关于张量的一些计算与我们所熟悉的线性代数却大相径庭，同时，张量计算相比以矩阵计算为主导的线性代数更为抽象，这使得很多与张量分解相关的内容看起来晦涩难懂。实际上，向量与矩阵都是张量的特例，可以被定义为低阶张量。一般而言，向量是第 1 阶张量，英文表述为 first-order tensor；矩阵是第 2 阶张量，英文表述为 second-order tensor；第 3 阶或者更高阶数的张量被称为高阶张量，英文表述为 higher-order tensor。在各类文献中，通常提到的张量都是特指高阶张量，当然，这在本书的叙述中也不例外。需要注意的是，在各类程序语言中，人们更愿意将张量称为多维数组。

在一个矩阵中，某一元素的位置可以说是“第 i 行、第 j 列”，即要描述某一元素的位置需用到行和列索引构成的组合 (i, j) 。类似地，在一个第 3 阶张量中，描述某一元素的位置需用到三个索引构成的组合，例如 (i, j, k) 。在处理稀疏矩阵或稀疏张量时，用索引来标记元素的位置会节省下一些不必要的存储开支。

1.1 向量与矩阵

1.2 张量

1.2.1 张量结构

1.2.2 高阶张量矩阵化

1.3 特殊代数结构

1.3.1 循环矩阵

循环矩阵 (circulant matrix) 是一种特殊的代数结构，广泛应用于信号处理等。从定义出发，给定任意向量 $\mathbf{x} = (x_1, x_2, \dots, x_T)^\top \in \mathbb{R}^T$ ，其对应的循环矩阵可写作如下形式：

$$\mathcal{C}(\mathbf{x}) \triangleq \begin{bmatrix} x_1 & x_T & \cdots & x_2 \\ x_2 & x_1 & \cdots & x_3 \\ \vdots & \vdots & \ddots & \vdots \\ x_T & x_{T-1} & \cdots & x_1 \end{bmatrix} \in \mathbb{R}^{T \times T} \quad (1.1)$$

其中, $\mathcal{C} : \mathbb{R}^T \rightarrow \mathbb{R}^{T \times T}$ 表示循环算子 (circulant operator)。该循环矩阵的第一列为向量 \mathbf{x} 本身, 对角线元素均为 x_1 。

例 1. 给定任意向量 $\mathbf{x} = (x_1, x_2, x_3, x_4, x_5)^\top \in \mathbb{R}^5$, 试写出其对应的循环矩阵。

解. 向量 \mathbf{x} 对应的循环矩阵为

$$\mathcal{C}(\mathbf{x}) = \begin{bmatrix} x_1 & x_5 & x_4 & x_3 & x_2 \\ x_2 & x_1 & x_5 & x_4 & x_3 \\ x_3 & x_2 & x_1 & x_5 & x_4 \\ x_4 & x_3 & x_2 & x_1 & x_5 \\ x_5 & x_4 & x_3 & x_2 & x_1 \end{bmatrix} \in \mathbb{R}^{5 \times 5} \quad (1.2)$$

例 2. 给定任意向量 $\mathbf{x} = (x_1, x_2, \dots, x_T)^\top \in \mathbb{R}^T$ 与 $\mathbf{y} = (y_1, y_2, \dots, y_T)^\top \in \mathbb{R}^T$, 若两者之间的循环卷积 (circular convolution) 为 $\mathbf{z} = \mathbf{x} \star \mathbf{y} \in \mathbb{R}^T$, 其中, 符号 \star 表示卷积运算, 则向量 \mathbf{z} 的任意元素为

$$z_t = \sum_{k=1}^T x_{t-k+1} y_k, \forall t \in \{1, 2, \dots, T\} \quad (1.3)$$

其中, 当 $t+1 \leq k$ 时, 则令 $x_{t-k+1} = x_{t-k+1+T}$ 。试根据循环矩阵的定义写出循环卷积。

解. 在这里, 循环卷积可写作如下形式:

$$\mathbf{z} = \mathbf{x} \star \mathbf{y} = \begin{bmatrix} x_1 y_1 + x_T y_2 + \dots + x_2 y_T \\ x_2 y_1 + x_1 y_2 + \dots + x_3 y_T \\ \vdots \\ x_T y_1 + x_{T-1} y_2 + \dots + x_1 y_T \end{bmatrix} = \begin{bmatrix} x_1 & x_T & \dots & x_2 \\ x_2 & x_1 & \dots & x_3 \\ \vdots & \vdots & \ddots & \vdots \\ x_T & x_{T-1} & \dots & x_1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_T \end{bmatrix} = \mathcal{C}(\mathbf{x}) \mathbf{y} \quad (1.4)$$

1.3.2 卷积矩阵

1.3.3 Hankel 矩阵

第二章 Kronecker 积与 Kronecker 分解

Kronecker 积是张量计算中非常重要的一种运算规则，不同于常见的矩阵运算规则，给定任意两个矩阵，两者之间进行 Kronecker 积得到的是一个分块矩阵。Kronecker 分解是一种以 Kronecker 积为基础的分解形式，又被称为 Kronecker 积分解、Kronecker 积逼近 (Kronecker product approximation)、最近 Kronecker 积 (nearest Kronecker product) 等，它是矩阵计算与张量计算中十分重要的逼近问题。本章首先介绍 Kronecker 积的定义与性质，然后引出 Kronecker 分解的一般形式、优化问题、求解过程等，最后给出以 Kronecker 分解为基础的模式参数压缩问题。

2.1 Kronecker 积定义

Kronecker 积是以德国数学家 Leopold Kronecker 的名字命名的运算规则，已广泛应用于各类矩阵计算以及张量计算算法中。从定义出发，给定任意矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 与 $\mathbf{Y} \in \mathbb{R}^{p \times q}$ ，则两者之间的 Kronecker 积为

$$\mathbf{X} \otimes \mathbf{Y} = \begin{bmatrix} x_{11}\mathbf{Y} & x_{12}\mathbf{Y} & \cdots & x_{1n}\mathbf{Y} \\ x_{21}\mathbf{Y} & x_{22}\mathbf{Y} & \cdots & x_{2n}\mathbf{Y} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1}\mathbf{Y} & x_{m2}\mathbf{Y} & \cdots & x_{mn}\mathbf{Y} \end{bmatrix} \in \mathbb{R}^{(mp) \times (nq)} \quad (2.1)$$

其中，符号 \otimes 表示 Kronecker 积。这里的 Kronecker 积得到的矩阵大小为 $(mp) \times (nq)$ ，在写法上符合线性代数中对分块矩阵 (block matrix) 的定义，其中，分块矩阵的子矩阵是由矩阵 \mathbf{X} 的每个元素与矩阵 \mathbf{Y} 相乘得到。

矩阵 \mathbf{X} 与 \mathbf{Y} 之间的 Kronecker 积存在前后顺序，根据 Kronecker 积的定义，可得到矩阵 \mathbf{Y} 与 \mathbf{X} 之间的 Kronecker 积为

$$\mathbf{Y} \otimes \mathbf{X} = \begin{bmatrix} y_{11}\mathbf{X} & y_{12}\mathbf{X} & \cdots & y_{1q}\mathbf{X} \\ y_{21}\mathbf{X} & y_{22}\mathbf{X} & \cdots & y_{2q}\mathbf{X} \\ \vdots & \vdots & \ddots & \vdots \\ y_{p1}\mathbf{X} & y_{p2}\mathbf{X} & \cdots & y_{pq}\mathbf{X} \end{bmatrix} \in \mathbb{R}^{(mp) \times (nq)} \quad (2.2)$$

尽管矩阵 $\mathbf{X} \otimes \mathbf{Y}$ 与矩阵 $\mathbf{Y} \otimes \mathbf{X}$ 大小一致，但两者并不相等，因此，Kronecker 积不存在交换律。

例 3. 给定矩阵 $\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 与 $\mathbf{Y} = \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix}$ ，试写出两者之间的 Kronecker 积 $\mathbf{X} \otimes \mathbf{Y}$ 与 $\mathbf{Y} \otimes \mathbf{X}$ 。

解. 根据 Kronecker 积定义, 有

$$\mathbf{X} \otimes \mathbf{Y} = \begin{bmatrix} 1 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} & 2 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} \\ 3 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} & 4 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 5 & 6 & 7 & 10 & 12 & 14 \\ 8 & 9 & 10 & 16 & 18 & 20 \\ 15 & 18 & 21 & 20 & 24 & 28 \\ 24 & 27 & 30 & 32 & 36 & 40 \end{bmatrix} \quad (2.3)$$

$$\mathbf{Y} \otimes \mathbf{X} = \begin{bmatrix} 5 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} & 6 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} & 7 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \\ 8 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} & 9 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} & 10 \times \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 5 & 10 & 6 & 12 & 7 & 14 \\ 15 & 20 & 18 & 24 & 21 & 28 \\ 8 & 16 & 9 & 18 & 10 & 20 \\ 24 & 32 & 27 & 36 & 30 & 40 \end{bmatrix} \quad (2.4)$$

例 4. 给定矩阵 $\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 与 $\mathbf{Y} = \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix}$, 试问等式 $(\mathbf{X} \otimes \mathbf{Y})^\top = \mathbf{X}^\top \otimes \mathbf{Y}^\top$ 是否成立。

解. 根据 Kronecker 积定义, 有

$$\mathbf{X}^\top \otimes \mathbf{Y}^\top = \begin{bmatrix} 1 \times \begin{bmatrix} 5 & 8 \\ 6 & 9 \\ 7 & 10 \end{bmatrix} & 3 \times \begin{bmatrix} 5 & 8 \\ 6 & 9 \\ 7 & 10 \end{bmatrix} \\ 2 \times \begin{bmatrix} 5 & 8 \\ 6 & 9 \\ 7 & 10 \end{bmatrix} & 4 \times \begin{bmatrix} 5 & 8 \\ 6 & 9 \\ 7 & 10 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 5 & 8 & 15 & 24 \\ 6 & 9 & 18 & 27 \\ 7 & 10 & 21 & 30 \\ 10 & 16 & 20 & 32 \\ 12 & 18 & 24 & 36 \\ 14 & 20 & 28 & 40 \end{bmatrix} \quad (2.5)$$

在这里, 等式 $(\mathbf{X} \otimes \mathbf{Y})^\top = \mathbf{X}^\top \otimes \mathbf{Y}^\top$ 是成立的。

例 5. 给定向量 $\mathbf{x} = (1, 2)^\top$ 与 $\mathbf{y} = (3, 4)^\top$, 试写出 $\mathbf{x} \otimes \mathbf{y}$ 与 $\mathbf{x} \otimes \mathbf{y}^\top$ 。

解. 根据 Kronecker 积定义, 有

$$\mathbf{x} \otimes \mathbf{y} = \begin{bmatrix} 1 \times \begin{bmatrix} 3 \\ 4 \end{bmatrix} \\ 2 \times \begin{bmatrix} 3 \\ 4 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \\ 6 \\ 8 \end{bmatrix} \quad (2.6)$$

$$\mathbf{x} \otimes \mathbf{y}^\top = \begin{bmatrix} 1 \times \begin{bmatrix} 3 & 4 \end{bmatrix} \\ 2 \times \begin{bmatrix} 3 & 4 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 3 & 4 \\ 6 & 8 \end{bmatrix} \quad (2.7)$$

在这里, $\mathbf{x} \otimes \mathbf{y}^\top = \mathbf{x}\mathbf{y}^\top$, 即向量外积。

2.2 Kronecker 积基本性质

2.2.1 结合律与分配律

在小学数学中, 我们学习了加减乘除的运算规则。以乘法为例, 不妨重温一下烙印在我们脑海中的基本概念:

- 乘法结合律: $x \times y \times z = x \times (y \times z)$
- 乘法分配律: $x \times z + y \times z = (x + y) \times z$

由于 Kronecker 积本质上也是元素间相乘, 所以同样存在结合律与分配律。对于任意矩阵 \mathbf{X} 、 \mathbf{Y} 与 \mathbf{Z} , 结合律可归纳为

$$\mathbf{X} \otimes \mathbf{Y} \otimes \mathbf{Z} = \mathbf{X} \otimes (\mathbf{Y} \otimes \mathbf{Z}) \quad (2.8)$$

分配律可归纳为

$$\mathbf{X} \otimes \mathbf{Z} + \mathbf{Y} \otimes \mathbf{Z} = (\mathbf{X} + \mathbf{Y}) \otimes \mathbf{Z} \quad (2.9)$$

例 6. 给定矩阵 $\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 、 $\mathbf{Y} = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$ 与 $\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$, 试写出 $\mathbf{X} \otimes \mathbf{Y} \otimes \mathbf{Z}$ 与 $\mathbf{X} \otimes (\mathbf{Y} \otimes \mathbf{Z})$ 。

解. 根据 Kronecker 积定义, 有

$$\mathbf{X} \otimes \mathbf{Y} = \begin{bmatrix} 5 & 6 & 10 & 12 \\ 7 & 8 & 14 & 16 \\ 15 & 18 & 20 & 24 \\ 21 & 24 & 28 & 32 \end{bmatrix} \quad (2.10)$$

$$\mathbf{Y} \otimes \mathbf{Z} = \begin{bmatrix} 5 & 5 & 6 & 6 \\ 5 & 5 & 6 & 6 \\ 7 & 7 & 8 & 8 \\ 7 & 7 & 8 & 8 \end{bmatrix} \quad (2.11)$$

从而, 可得到

$$\mathbf{X} \otimes \mathbf{Y} \otimes \mathbf{Z} = \begin{bmatrix} 5 & 5 & 6 & 6 & 10 & 10 & 12 & 12 \\ 5 & 5 & 6 & 6 & 10 & 10 & 12 & 12 \\ 7 & 7 & 8 & 8 & 14 & 14 & 16 & 16 \\ 7 & 7 & 8 & 8 & 14 & 14 & 16 & 16 \\ 15 & 15 & 18 & 18 & 20 & 20 & 24 & 24 \\ 15 & 15 & 18 & 18 & 20 & 20 & 24 & 24 \\ 21 & 21 & 24 & 24 & 28 & 28 & 32 & 32 \\ 21 & 21 & 24 & 24 & 28 & 28 & 32 & 32 \end{bmatrix} = \mathbf{X} \otimes (\mathbf{Y} \otimes \mathbf{Z}) \quad (2.12)$$

例 7. 给定 $\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 、 $\mathbf{Y} = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$ 与 $\mathbf{Z} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$, 试写出 $\mathbf{X} \otimes \mathbf{Z} + \mathbf{Y} \otimes \mathbf{Z}$ 与 $(\mathbf{X} + \mathbf{Y}) \otimes \mathbf{Z}$ 。

解. 根据 Kronecker 积定义, 有

$$\mathbf{X} \otimes \mathbf{Z} + \mathbf{Y} \otimes \mathbf{Z} = \begin{bmatrix} 1 & 1 & 2 & 2 \\ 1 & 1 & 2 & 2 \\ 3 & 3 & 4 & 4 \\ 3 & 3 & 4 & 4 \end{bmatrix} + \begin{bmatrix} 5 & 5 & 6 & 6 \\ 5 & 5 & 6 & 6 \\ 7 & 7 & 8 & 8 \\ 7 & 7 & 8 & 8 \end{bmatrix} = \begin{bmatrix} 6 & 6 & 8 & 8 \\ 6 & 6 & 8 & 8 \\ 10 & 10 & 12 & 12 \\ 10 & 10 & 12 & 12 \end{bmatrix} \quad (2.13)$$

$$(\mathbf{X} + \mathbf{Y}) \otimes \mathbf{Z} = \begin{bmatrix} 6 & 8 \\ 10 & 12 \end{bmatrix} \otimes \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 6 & 6 & 8 & 8 \\ 6 & 6 & 8 & 8 \\ 10 & 10 & 12 & 12 \\ 10 & 10 & 12 & 12 \end{bmatrix} \quad (2.14)$$

2.2.2 矩阵相乘

对于任意矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{Y} \in \mathbb{R}^{s \times t}$ 、 $\mathbf{U} \in \mathbb{R}^{n \times p}$ 与 $\mathbf{V} \in \mathbb{R}^{t \times q}$, 则矩阵 $\mathbf{X} \otimes \mathbf{Y} \in \mathbb{R}^{(ms) \times (nt)}$ 的列数 nt 与矩阵 $\mathbf{U} \otimes \mathbf{V} \in \mathbb{R}^{(nt) \times (pq)}$ 的行数 nt 一致, 可进行矩阵相乘, 两者相乘得到的矩阵满足:

$$\begin{aligned}
 (\mathbf{X} \otimes \mathbf{Y})(\mathbf{U} \otimes \mathbf{V}) &= \begin{bmatrix} x_{11}\mathbf{Y} & \cdots & x_{1n}\mathbf{Y} \\ \vdots & \ddots & \vdots \\ x_{m1}\mathbf{Y} & \cdots & x_{mn}\mathbf{Y} \end{bmatrix} \begin{bmatrix} u_{11}\mathbf{V} & \cdots & u_{1p}\mathbf{V} \\ \vdots & \ddots & \vdots \\ u_{n1}\mathbf{V} & \cdots & u_{np}\mathbf{V} \end{bmatrix} \\
 &= \begin{bmatrix} \sum_{k=1}^n x_{1k}u_{k1}\mathbf{YV} & \cdots & \sum_{k=1}^n x_{1k}u_{kp}\mathbf{YV} \\ \vdots & \ddots & \vdots \\ \sum_{k=1}^n x_{mk}u_{k1}\mathbf{YV} & \cdots & \sum_{k=1}^n x_{mk}u_{kp}\mathbf{YV} \end{bmatrix} \\
 &= \begin{bmatrix} \sum_{k=1}^n x_{1k}u_{k1} & \cdots & \sum_{k=1}^n x_{1k}u_{kp} \\ \vdots & \ddots & \vdots \\ \sum_{k=1}^n x_{mk}u_{k1} & \cdots & \sum_{k=1}^n x_{mk}u_{kp} \end{bmatrix} \otimes (\mathbf{YV}) \\
 &= (\mathbf{XU}) \otimes (\mathbf{YV}) \in \mathbb{R}^{(ms) \times (pq)}
 \end{aligned} \tag{2.15}$$

2.2.3 求逆矩阵

对于任意可逆矩阵 $\mathbf{X} \in \mathbb{R}^{m \times m}$ 与 $\mathbf{Y} \in \mathbb{R}^{n \times n}$, 由于

$$(\mathbf{X} \otimes \mathbf{Y})(\mathbf{X}^{-1} \otimes \mathbf{Y}^{-1}) = (\mathbf{X}\mathbf{X}^{-1}) \otimes (\mathbf{Y}\mathbf{Y}^{-1}) = \mathbf{I}_m \otimes \mathbf{I}_n = \mathbf{I}_{mn} \tag{2.16}$$

故有

$$(\mathbf{X} \otimes \mathbf{Y})^{-1} = \mathbf{X}^{-1} \otimes \mathbf{Y}^{-1} \tag{2.17}$$

恒成立。这意味着: 若计算 $\mathbf{X} \otimes \mathbf{Y}$ 的逆矩阵, 可先对 \mathbf{X} 与 \mathbf{Y} 分别求逆矩阵, 再对得到的逆矩阵进行 Kronecker 积。

例 8. 给定矩阵 $\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 与 $\mathbf{Y} = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$, 试写出 $(\mathbf{X} \otimes \mathbf{Y})^{-1}$ 与 $\mathbf{X}^{-1} \otimes \mathbf{Y}^{-1}$ 。

解. 根据 Kronecker 积定义, 有

$$\mathbf{X} \otimes \mathbf{Y} = \begin{bmatrix} 5 & 6 & 10 & 12 \\ 7 & 8 & 14 & 16 \\ 15 & 18 & 20 & 24 \\ 21 & 24 & 28 & 32 \end{bmatrix} \tag{2.18}$$

对该矩阵求逆矩阵, 得到

$$(\mathbf{X} \otimes \mathbf{Y})^{-1} = \begin{bmatrix} 8 & -6 & -4 & 3 \\ -7 & 5 & 3.5 & -2.5 \\ -6 & 4.5 & 2 & -1.5 \\ 5.25 & -3.75 & -1.75 & 1.25 \end{bmatrix} \tag{2.19}$$

对矩阵 \mathbf{X} 与 \mathbf{Y} 分别求逆矩阵:

$$\mathbf{X}^{-1} = \begin{bmatrix} -2 & 1 \\ 1.5 & -0.5 \end{bmatrix} \quad \mathbf{Y}^{-1} = \begin{bmatrix} -4 & 3 \\ 3.5 & -2.5 \end{bmatrix} \tag{2.20}$$

再对得到的逆矩阵进行 *Kronecker* 积, 有

$$\mathbf{X}^{-1} \otimes \mathbf{Y}^{-1} = \begin{bmatrix} 8 & -6 & -4 & 3 \\ -7 & 5 & 3.5 & -2.5 \\ -6 & 4.5 & 2 & -1.5 \\ 5.25 & -3.75 & -1.75 & 1.25 \end{bmatrix} \quad (2.21)$$

2.2.4 向量化

2.3 Kronecker 积特殊性质

2.4 朴素 Kronecker 分解

2.4.1 定义

一般而言, 给定任意矩阵 $\mathbf{X} \in \mathbb{R}^{(mp) \times (nq)}$, 若 $\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{B} \in \mathbb{R}^{p \times q}$ 为朴素 Kronecker 分解中的待定参数, 则可将分解过程描述为如下优化问题:

$$\min_{\mathbf{A}, \mathbf{B}} \|\mathbf{X} - \mathbf{A} \otimes \mathbf{B}\|_F^2 \quad (2.22)$$

其中, 我们建模的目标是寻找最佳的矩阵 \mathbf{A}, \mathbf{B} 使得损失函数最小化。

为便于理解该优化问题, 不妨用一组小矩阵一窥究竟, 令 $m = 3, n = p = q = 2$, 则此时的目标函数为

$$\|\mathbf{X} - \mathbf{A} \otimes \mathbf{B}\|_F^2 = \left\| \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \\ x_{41} & x_{42} & x_{43} & x_{44} \\ x_{51} & x_{52} & x_{53} & x_{54} \\ x_{61} & x_{62} & x_{63} & x_{64} \end{bmatrix} - \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix} \otimes \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} \right\|_F^2 \quad (2.23)$$

2.4.2 引入 permute 概念

在这里, 我们引入 permute 概念是为了对矩阵的维度按照特定规则进行调整, 这一做法最早是由 Van Loan 和 Pitsianis 于 1993 年提出的¹。在公式(2.23)中, 首先使用分块矩阵表示矩阵 $\mathbf{X} \in \mathbb{R}^{6 \times 4}$:

$$\begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & x_{34} \\ x_{41} & x_{42} & x_{43} & x_{44} \\ x_{51} & x_{52} & x_{53} & x_{54} \\ x_{61} & x_{62} & x_{63} & x_{64} \end{bmatrix} = \begin{bmatrix} \mathbf{X}_{11} & \mathbf{X}_{12} \\ \mathbf{X}_{21} & \mathbf{X}_{22} \\ \mathbf{X}_{31} & \mathbf{X}_{32} \end{bmatrix} \quad (2.24)$$

¹C. Van Loan, N. Pitsianis (1993). Approximation with Kronecker products. Linear Algebra for Large Scale and Real-Time Applications, 232: 293-314.

其中, 分块矩阵的子矩阵分别为

$$\begin{aligned} \mathbf{X}_{11} &= \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix} & \mathbf{X}_{12} &= \begin{bmatrix} x_{13} & x_{14} \\ x_{23} & x_{24} \end{bmatrix} \\ \mathbf{X}_{21} &= \begin{bmatrix} x_{31} & x_{32} \\ x_{41} & x_{42} \end{bmatrix} & \mathbf{X}_{22} &= \begin{bmatrix} x_{33} & x_{34} \\ x_{43} & x_{44} \end{bmatrix} \\ \mathbf{X}_{31} &= \begin{bmatrix} x_{51} & x_{52} \\ x_{61} & x_{62} \end{bmatrix} & \mathbf{X}_{32} &= \begin{bmatrix} x_{53} & x_{54} \\ x_{63} & x_{64} \end{bmatrix} \end{aligned} \quad (2.25)$$

有了这些子矩阵之后, 需要对这些子矩阵进行向量化, 得到的向量依次为

$$\text{vec}(\mathbf{X}_{11}) = \begin{bmatrix} x_{11} \\ x_{21} \\ x_{12} \\ x_{22} \end{bmatrix} \quad \text{vec}(\mathbf{X}_{21}) = \begin{bmatrix} x_{31} \\ x_{41} \\ x_{32} \\ x_{42} \end{bmatrix} \quad \cdots \quad \text{vec}(\mathbf{X}_{32}) = \begin{bmatrix} x_{53} \\ x_{63} \\ x_{54} \\ x_{64} \end{bmatrix} \quad (2.26)$$

最后, 使用这些向量构造如下矩阵:

$$\tilde{\mathbf{X}} = \begin{bmatrix} \text{vec}(\mathbf{X}_{11})^\top \\ \text{vec}(\mathbf{X}_{21})^\top \\ \text{vec}(\mathbf{X}_{31})^\top \\ \text{vec}(\mathbf{X}_{12})^\top \\ \text{vec}(\mathbf{X}_{22})^\top \\ \text{vec}(\mathbf{X}_{32})^\top \end{bmatrix} \in \mathbb{R}^{6 \times 4} \quad (2.27)$$

在这里, 将矩阵 \mathbf{X} 构造成矩阵 $\tilde{\mathbf{X}}$ 的过程通常被称为 permute。

由于

$$\begin{aligned} \text{vec}(\mathbf{X}_{11}) &= a_{11} \cdot \text{vec}(\mathbf{B}) \\ \text{vec}(\mathbf{X}_{21}) &= a_{21} \cdot \text{vec}(\mathbf{B}) \\ &\vdots \\ \text{vec}(\mathbf{X}_{32}) &= a_{32} \cdot \text{vec}(\mathbf{B}) \end{aligned} \quad (2.28)$$

此时, Kronecker 分解的优化问题可写作如下形式:

$$\arg \min_{\mathbf{A}, \mathbf{B}} \|\mathbf{X} - \mathbf{A} \otimes \mathbf{B}\|_F^2 = \arg \min_{\mathbf{A}, \mathbf{B}} \|\tilde{\mathbf{X}} - \text{vec}(\mathbf{A})\text{vec}(\mathbf{B})^\top\|_F^2 \quad (2.29)$$

实际上, 向量化之后的待定参数 $\text{vec}(\mathbf{A})$ 和 $\text{vec}(\mathbf{B})$ 构成了一个标准的矩阵分解问题。

2.4.3 求解过程

对于公式(2.22)中 Kronecker 分解的优化问题, 可根据 Eckhart-Young 定理对如下优化问题进行求解:

$$\min_{\mathbf{A}, \mathbf{B}} \|\tilde{\mathbf{X}} - \text{vec}(\mathbf{A})\text{vec}(\mathbf{B})^\top\|_F^2 \quad (2.30)$$

若 $\tilde{\mathbf{X}}$ 的奇异值分解为 $\tilde{\mathbf{X}} = \sum_{r=1}^{\min\{mn, pq\}} \sigma_r \mathbf{u}_r \mathbf{v}_r^\top$, 其中, 奇异值为 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{\min\{mn, pq\}}$, 则矩阵 \mathbf{A} 与 \mathbf{B} 的最优解为

$$\begin{cases} \text{vec}(\hat{\mathbf{A}}) = \sqrt{\sigma_1} \cdot \mathbf{u}_1 \\ \text{vec}(\hat{\mathbf{B}}) = \sqrt{\sigma_2} \cdot \mathbf{v}_1 \end{cases} \quad (2.31)$$

这里的最优解恰好是秩为 1 的逼近问题。

例 9. 给定矩阵 $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 与 $B = \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix}$, 试写出两者之间的 Kronecker 积 $X = A \otimes B$, 并求 Kronecker 分解 $\hat{A}, \hat{B} = \arg \min_{A, B} \|X - A \otimes B\|_F^2$ 。

解. 矩阵 A 与 B 之间的 Kronecker 积为

$$X = A \otimes B = \begin{bmatrix} 1 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} & 2 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} \\ 3 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} & 4 \times \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 5 & 6 & 7 & 10 & 12 & 14 \\ 8 & 9 & 10 & 16 & 18 & 20 \\ 15 & 18 & 21 & 20 & 24 & 28 \\ 24 & 27 & 30 & 32 & 36 & 40 \end{bmatrix} \quad (2.32)$$

令分块矩阵 X 由如下 4 个子矩阵构成:

$$\begin{aligned} X_{11} &= \begin{bmatrix} 5 & 6 & 7 \\ 8 & 9 & 10 \end{bmatrix} & X_{12} &= \begin{bmatrix} 10 & 12 & 14 \\ 16 & 18 & 20 \end{bmatrix} \\ X_{21} &= \begin{bmatrix} 15 & 18 & 21 \\ 24 & 27 & 30 \end{bmatrix} & X_{22} &= \begin{bmatrix} 20 & 24 & 28 \\ 32 & 36 & 40 \end{bmatrix} \end{aligned} \quad (2.33)$$

对这些子矩阵分别进行向量化:

$$\begin{aligned} \text{vec}(X_{11}) &= \begin{bmatrix} 5 \\ 8 \\ 6 \\ 9 \\ 7 \\ 10 \end{bmatrix} & \text{vec}(X_{21}) &= \begin{bmatrix} 15 \\ 24 \\ 18 \\ 27 \\ 21 \\ 30 \end{bmatrix} & \text{vec}(X_{12}) &= \begin{bmatrix} 10 \\ 16 \\ 12 \\ 18 \\ 14 \\ 20 \end{bmatrix} & \text{vec}(X_{22}) &= \begin{bmatrix} 20 \\ 32 \\ 24 \\ 36 \\ 28 \\ 40 \end{bmatrix} \end{aligned} \quad (2.34)$$

有了这些向量之后, 构造如下矩阵:

$$\tilde{X} = \begin{bmatrix} \text{vec}(X_{11})^\top \\ \text{vec}(X_{21})^\top \\ \text{vec}(X_{12})^\top \\ \text{vec}(X_{22})^\top \end{bmatrix} = \begin{bmatrix} 5 & 8 & 6 & 9 & 7 & 10 \\ 15 & 24 & 18 & 27 & 21 & 30 \\ 10 & 16 & 12 & 18 & 14 & 20 \\ 20 & 32 & 24 & 36 & 28 & 40 \end{bmatrix} \quad (2.35)$$

由此, Kronecker 分解的优化问题等价于

$$\hat{A}, \hat{B} = \arg \min_{A, B} \|\tilde{X} - \text{vec}(A)\text{vec}(B)^\top\|_F^2 \quad (2.36)$$

对矩阵 \tilde{X} 进行奇异值分解, 则矩阵 \hat{A} 与 \hat{B} 分别为

$$\begin{aligned} \hat{A} &= \begin{bmatrix} -1.85471325 & -3.7094265 \\ -5.56413975 & -7.418853 \end{bmatrix} \\ \hat{B} &= \begin{bmatrix} -2.69583452 & -3.23500142 & -3.77416832 \\ -4.31333523 & -4.85250213 & -5.39166904 \end{bmatrix} \end{aligned} \quad (2.37)$$

在这里, 矩阵 \hat{A} 与 \hat{B} 的所有元素均为负数, 可将这些元素全部写成相反数。

2.5 广义 Kronecker 分解

在《Convolutional neural network compression through generalized Kronecker product decomposition》中, 作者给出了一种广义 Kronecker 分解。形式上说, 给定任意矩阵 $X \in$

$\mathbb{R}^{(mp) \times (nq)}$, 若 $\mathbf{A}_r \in \mathbb{R}^{m \times n}$, $\mathbf{B}_r \in \mathbb{R}^{p \times q}$, $r = 1, 2, \dots, R$ 为广义 Kronecker 分解中的待定参数, 则可将分解过程描述为如下逼近问题:

$$\min_{\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R} \left\| \mathbf{X} - \sum_{r=1}^R \mathbf{A}_r \otimes \mathbf{B}_r \right\|_F^2 \quad (2.38)$$

其中, 我们的建模目标是寻找最佳的矩阵 $\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R$ 使得损失函数最小化。

与朴素 Kronecker 分解类似, 可先将广义 Kronecker 分解的逼近问题写作如下形式:

$$\arg \min_{\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R} \left\| \mathbf{X} - \sum_{r=1}^R \mathbf{A}_r \otimes \mathbf{B}_r \right\|_F^2 = \arg \min_{\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R} \left\| \mathbf{X} - \sum_{r=1}^R \text{vec}(\mathbf{A}_r) \text{vec}(\mathbf{B}_r)^\top \right\|_F^2 \quad (2.39)$$

其中, 矩阵 $\tilde{\mathbf{X}}$ 是由矩阵 \mathbf{X} 进行 permute 构造得到。

根据 Eckhart-Young 定理对上述优化问题进行求解, 若矩阵 $\tilde{\mathbf{X}}$ 的奇异值分解为 $\tilde{\mathbf{X}} = \sum_{r=1}^{\min\{mn, pq\}} \sigma_r \mathbf{u}_r \mathbf{v}_r^\top$, 其中, 奇异值为 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min\{mn, pq\}}$, 则矩阵 \mathbf{A}_r 和 \mathbf{B}_r 的最优解为

$$\begin{cases} \text{vec}(\hat{\mathbf{A}}_r) = \sqrt{\sigma_r} \mathbf{u}_r \\ \text{vec}(\hat{\mathbf{B}}_r) = \sqrt{\sigma_r} \mathbf{v}_r \end{cases} \quad (2.40)$$

2.6 模型参数压缩问题

Kronecker 分解的一个重要用途是压缩模型参数。以多元线性回归 (multivariate linear regression) 为例, 给定输入、输出数据为 $\mathcal{D} = \{(\mathbf{x}_1, \mathbf{y}_1), \dots, (\mathbf{x}_N, \mathbf{y}_N)\} \in \mathbb{R}^{nq} \times \mathbb{R}^{mp}$, 则多元线性回归的优化问题为

$$\min_{\mathbf{W}} \frac{1}{2} \sum_{n=1}^N \|\mathbf{y}_n - \mathbf{W} \mathbf{x}_n\|_2^2 \quad (2.41)$$

令

$$\mathbf{X} = \begin{bmatrix} | & & | \\ \mathbf{x}_1 & \cdots & \mathbf{x}_N \\ | & & | \end{bmatrix} \in \mathbb{R}^{nq \times N} \quad (2.42)$$

$$\mathbf{Y} = \begin{bmatrix} | & & | \\ \mathbf{y}_1 & \cdots & \mathbf{y}_N \\ | & & | \end{bmatrix} \in \mathbb{R}^{mp \times N}, \quad (2.43)$$

则此时多元线性回归的等价优化问题为

$$\min_{\mathbf{W}} \frac{1}{2} \|\mathbf{Y} - \mathbf{W} \mathbf{X}\|_F^2 \quad (2.44)$$

不妨假设这里的系数矩阵 $\mathbf{W} \in \mathbb{R}^{(mp) \times (nq)}$ 存在一个广义 Kronecker 分解, 且由 R 个成分构成, 则基于广义 Kronecker 分解的多元线性回归可写作如下形式:

$$\min_{\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R} \frac{1}{2} \left\| \mathbf{Y} - \sum_{r=1}^R (\mathbf{A}_r \otimes \mathbf{B}_r) \mathbf{X} \right\|_F^2 \quad (2.45)$$

将优化问题改写为如下形式即可得到一个标准的广义 Kronecker 分解:

$$\min_{\{\mathbf{A}_r, \mathbf{B}_r\}_{r=1}^R} \frac{1}{2} \left\| \mathbf{Y} \mathbf{X}^\dagger - \sum_{r=1}^R (\mathbf{A}_r \otimes \mathbf{B}_r) \right\|_F^2 \quad (2.46)$$

从而可根据广义 Kronecker 分解的求解方法对该多元线性回归问题进行求解。

例 10 (矩阵自回归模型²). 对于多维时间序列 (*multidimensional time series*), 若任意时刻 t 对应的观测数据为矩阵 $\mathbf{X}_t \in \mathbb{R}^{M \times N}$, 则矩阵自回归的表达式为

$$\mathbf{X}_t = \mathbf{A}\mathbf{X}_{t-1}\mathbf{B}^\top + \mathbf{E}_t, t = 2, 3, \dots, T \quad (2.47)$$

其中, $\mathbf{A} \in \mathbb{R}^{M \times M}$ 与 $\mathbf{B} \in \mathbb{R}^{N \times N}$ 为自回归过程的系数矩阵 (*coefficient matrix*); 矩阵 $\mathbf{E}_t \in \mathbb{R}^{M \times N}$ 为自回归过程的残差矩阵 (*residual matrix*). 若令 $\mathbf{x}_t = \text{vec}(\mathbf{X}_t)$ 与 $\boldsymbol{\epsilon}_t = \text{vec}(\mathbf{E}_t)$, 试写出与矩阵自回归等价的向量自回归表达式。

解. 根据 *Kronecker* 积性质, 矩阵自回归等价于如下向量自回归:

$$\begin{aligned} \text{vec}(\mathbf{X}_t) &= \text{vec}(\mathbf{A}\mathbf{X}_{t-1}\mathbf{B}^\top) + \text{vec}(\mathbf{E}_t) \\ &= (\mathbf{B} \otimes \mathbf{A})\text{vec}(\mathbf{X}_{t-1}) + \text{vec}(\mathbf{E}_t) \\ \implies \mathbf{x}_t &= (\mathbf{B} \otimes \mathbf{A})\mathbf{x}_{t-1} + \boldsymbol{\epsilon}_t \end{aligned} \quad (2.48)$$

在这里, 矩阵自回归的待定参数数量为 $M^2 + N^2$, 若对观测数据进行向量化且不对系数矩阵进行 *Kronecker* 分解, 则向量自回归的待定参数数量为 $(MN)^2$, 容易引发过参数化 (*over-parameterization*) 问题。

²http://www.stat.rutgers.edu/home/rongchen/publications/20JoE_Matrix_AR.pdf

第三章 模态积与 Tucker 张量分解

3.1 模态积定义

例 11 (矩阵自回归模型).

3.2 模态积性质

3.3 高阶奇异值分解

3.4 Tucker 分解

第四章 低秩线性回归

线性回归是机器学习中的一个基本模型，常用于各类回归问题，其建模思路是采用线性方程对给定的变量建立线性关系。本章以线性回归模型为基础，将介绍低秩线性回归模型、低秩自回归模型、时变低秩自回归模型等，这些模型的核心是借助矩阵分解或张量分解对模型参数进行压缩。

4.1 低秩线性回归

4.2 高维向量自回归

4.3 时变低秩向量自回归